几何计算前沿
第四次作业报告
基于 MLP 的从点云重建表面

刘智琦 2300012860

May 25, 2026

Contents

1 方法概述 **2**

2 神经网络模型与方法细节 **2**
2.1 基础模型：Vanilla MLP 2
2.2 拓展模型：Fourier Feature MLP 2
2.3 损失函数 3

3 训练策略 **3**
3.1 超参数设置 3
3.2 设计说明 3

4 训练与重建时间 **3**

5 重建结果 **4**
5.1 量化指标 4
5.2 可视化结果 4
5.3 结果分析 10

6 拓展任务：Fourier Feature 对比分析 **11**
6.1 原理 11
6.2 实验结果对比 11
6.3 从可视化图像中观察 11
6.4 局限性 11

7 结论 **12**

1 方法概述

本次作业实现了基于 MLP（多层感知机）的隐式表面重建方法。网络以空间查询点坐标为输入，输出该点的符号距离函数（SDF）值。训练完成后，在均匀格点上计算 SDF，再用 Marching Cubes 算法提取零等值面，得到重建表面。

同时实现了拓展任务：基于 Fourier Feature 的位置编码，将查询点坐标先映射到高维频率空间，再输入 MLP，以提升对高频细节的表达能力。

2 神经网络模型与方法细节

2.1 基础模型：**Vanilla MLP**

网络结构：8 层全连接网络，每层宽度 256，激活函数为 ReLU，第 4 层处引入跳跃连接（Skip Connection），将输入坐标拼接到第 4 层的输入特征上。结构如下：

$$h_0 = \mathrm{ReLU}(W_0\, q + b_0) \tag{1}$$

$$h_i = \mathrm{ReLU}(W_i\, h_{i-1} + b_i), \quad i = 1, 2, 3 \tag{2}$$

$$h_4 = \mathrm{ReLU}(W_4\, [h_3;\, q] + b_4) \quad \text{（跳跃连接）} \tag{3}$$

$$h_i = \mathrm{ReLU}(W_i\, h_{i-1} + b_i), \quad i = 5, 6, 7 \tag{4}$$

$$\tilde{F}(q) = W_{\text{out}}\, h_7 + b_{\text{out}} \tag{5}$$

输入维度为 3（(x, y, z) 坐标），输出维度为 1（SDF 值）。

参数量：

- 第 0 层：$3 \times 256 + 256 = 1{,}024$
- 第 1—3 层（各）：$256 \times 256 + 256 = 65{,}792$（共 3 层）
- 第 4 层（跳跃）：$(256 + 3) \times 256 + 256 = 66{,}048$
- 第 5—7 层（各）：$256 \times 256 + 256 = 65{,}792$（共 3 层）
- 输出层：$256 \times 1 + 1 = 257$

总参数量：**462**,**593**

2.2 拓展模型：**Fourier Feature MLP**

位置编码：参考 Tancik 等人 [1]，对输入坐标 $q \in \mathbb{R}^3$ 进行随机 Fourier 特征映射：

$$\gamma(q) = [\sin(2\pi \mathbf{B} q),\ \cos(2\pi \mathbf{B} q)]^\top \in \mathbb{R}^{2L} \tag{6}$$

其中 $\mathbf{B} \in \mathbb{R}^{L \times 3}$ 为固定随机矩阵，每个元素从 $\mathcal{N}(0, \sigma^2)$ 采样。本实验取 $L = 256$，$\sigma = 10$，编码维度为 $2 \times 256 = 512$。

网络结构：与 Vanilla MLP 相同（8 层，宽度 256，跳跃连接），但输入维度改为 512（Fourier 编码后的维度）。

总参数量：

- Fourier 矩阵 $\mathbf{B}$：$256 \times 3 = 768$（不参与训练，仅作缓冲区）
- 第 0 层：$512 \times 256 + 256 = 131{,}328$
- 第 4 层（跳跃）：$(256 + 512) \times 256 + 256 = 196{,}864$
- 其余层与 Vanilla 相同

总可训练参数量：**723**,**201**

2.3 损失函数

$$\mathcal{L} = \frac{1}{|B|} \sum_{q_i \in B} \left[\left(\tilde{F}(q_i) - F(q_i) \right)^2 + \lambda \left\| \nabla_{q_i} \tilde{F}(q_i) - N(q_i) \right\|^2 \right] \tag{7}$$

其中 $F(q_i)$ 为真实 SDF 值，$N(q_i)$ 为真实 SDF 梯度（单位法向量），B 为随机采样的 mini-batch，λ 为梯度损失权重（本实验取 $\lambda = 0.1$）。

梯度 $\nabla_{q_i} \tilde{F}$ 通过 `torch.autograd.grad` 对输入坐标求导计算。

3 训练策略

3.1 超参数设置

Table 1: 训练超参数

超参数	值
优化器	Adam
学习率	10^{-3}，余弦退火衰减至 10^{-5}
批量大小	16,384（从约 93 万样本中随机采样）
训练轮数	2,000
梯度损失权重 λ	0.1
Fourier 频率数 L	256
Fourier 标准差 σ	10.0
Marching Cubes 分辨率	128^3

3.2 设计说明

- 跳跃连接：参照 DeepSDF [2] 的做法，在第 4 层引入跳跃连接，帮助梯度流动、防止深层网络退化。
- 余弦退火：使学习率平滑衰减，后期精细优化。
- 随机采样：每步随机采样 16,384 个点（约占总样本 1.8%），避免内存瓶颈，同时提供足够多样的梯度信号。
- 梯度损失权重：$\lambda = 0.1$ 在 SDF 拟合精度和梯度（法向）一致性之间取得平衡。

4 训练与重建时间

实验在 NVIDIA RTX 5090（32 GB VRAM）上运行。

Table 2: 各形状的训练与重建时间

Shape	Vanilla MLP		Fourier MLP	
	训练 (s)	重建 (s)	训练 (s)	重建 (s)
Shape 1 (1a04e3)	40.3	0.13	48.6	0.15
Shape 2 (1a32f1)	35.7	0.13	37.5	0.17
Shape 3 (1a54a2)	35.0	0.12	38.4	0.17
Shape 4 (1a6ad7)	36.1	0.13	42.8	0.19
Shape 5 (1a9b55)	39.8	0.13	43.7	0.15
总计	**186.9**	**0.64**	**211.0**	**0.83**

Fourier MLP 训练时间比 Vanilla 约多 13%，主要来自更大的输入层（512 维 vs 3 维）和编码计算。Marching Cubes 重建时间很短（约 0.1–0.2 s/shape）。

5 重建结果

5.1 量化指标

Table 3: 各形状最终损失（2000 epoch 末）

Shape	Vanilla MLP			Fourier MLP		
	$\mathcal{L}$	$\mathcal{L}_{\text{sdf}}$	$\mathcal{L}_{\text{grad}}$	$\mathcal{L}$	$\mathcal{L}_{\text{sdf}}$	$\mathcal{L}_{\text{grad}}$
Shape 1	0.01335	0.00077	0.12578	**0.00557**	0.00368	**0.01885**
Shape 2	0.01318	**0.00185**	0.11338	0.01536	0.01089	**0.04471**
Shape 3	0.01512	**0.00153**	0.13592	**0.01464**	0.00939	**0.05253**
Shape 4	0.01929	**0.00204**	0.17258	**0.01196**	0.00555	**0.06405**
Shape 5	0.01628	**0.00117**	0.15110	**0.01071**	0.00657	**0.04142**

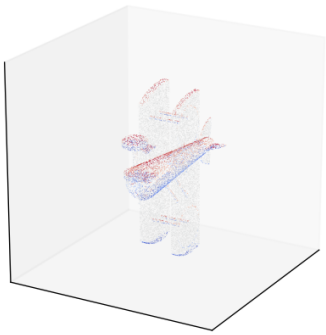
Table 4: 重建网格信息

Shape	Vanilla MLP		Fourier MLP	
	顶点数	面片数	顶点数	面片数
Shape 1	14,669	29,330	10,996	21,896
Shape 2	3,416	6,828	1,476	2,948
Shape 3	3,858	7,712	1,692	3,360
Shape 4	3,654	7,304	1,954	3,900
Shape 5	7,110	14,216	4,857	9,690

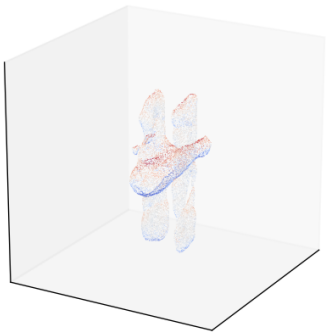
5.2 可视化结果

图 1 展示所有五个形状的重建对比（从左到右：Ground Truth、Vanilla MLP、Fourier MLP）。

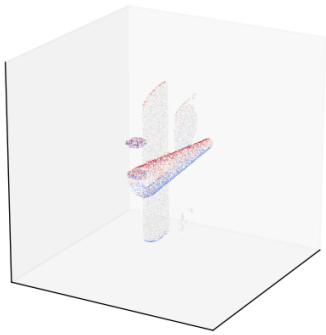
Shape 1 - GT



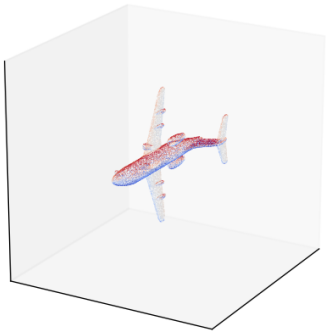
Shape 1 - Vanilla



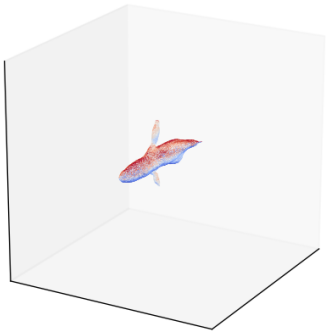
Shape 1 - Fourier



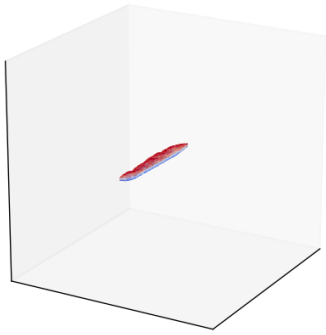
Shape 2 - GT



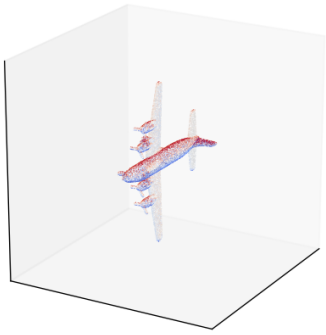
Shape 2 - Vanilla



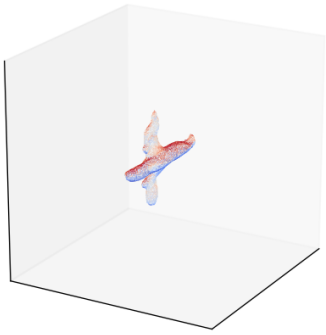
Shape 2 - Fourier



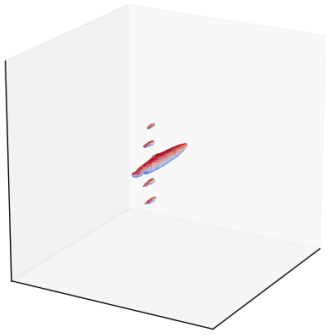
Shape 3 - GT



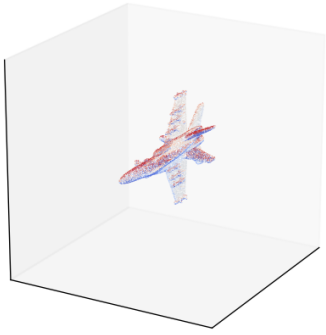
Shape 3 - Vanilla



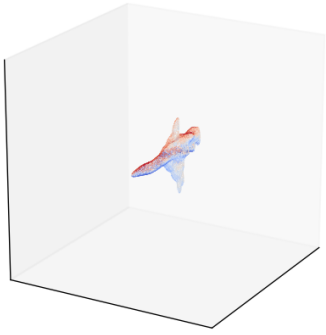
Shape 3 - Fourier



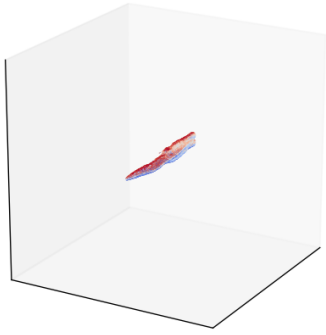
Shape 4 - GT



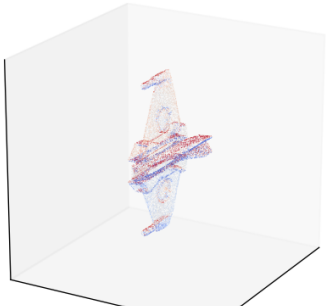
Shape 4 - Vanilla



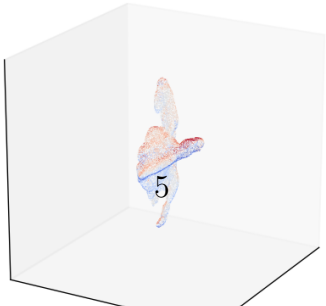
Shape 4 - Fourier



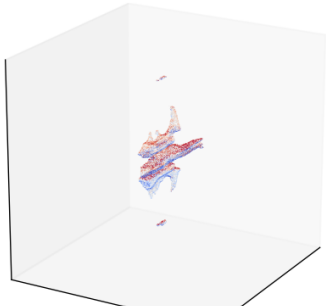
Shape 5 - GT



Shape 5 - Vanilla



Shape 5 - Fourier



各形状的两视角对比图见图 2–6。

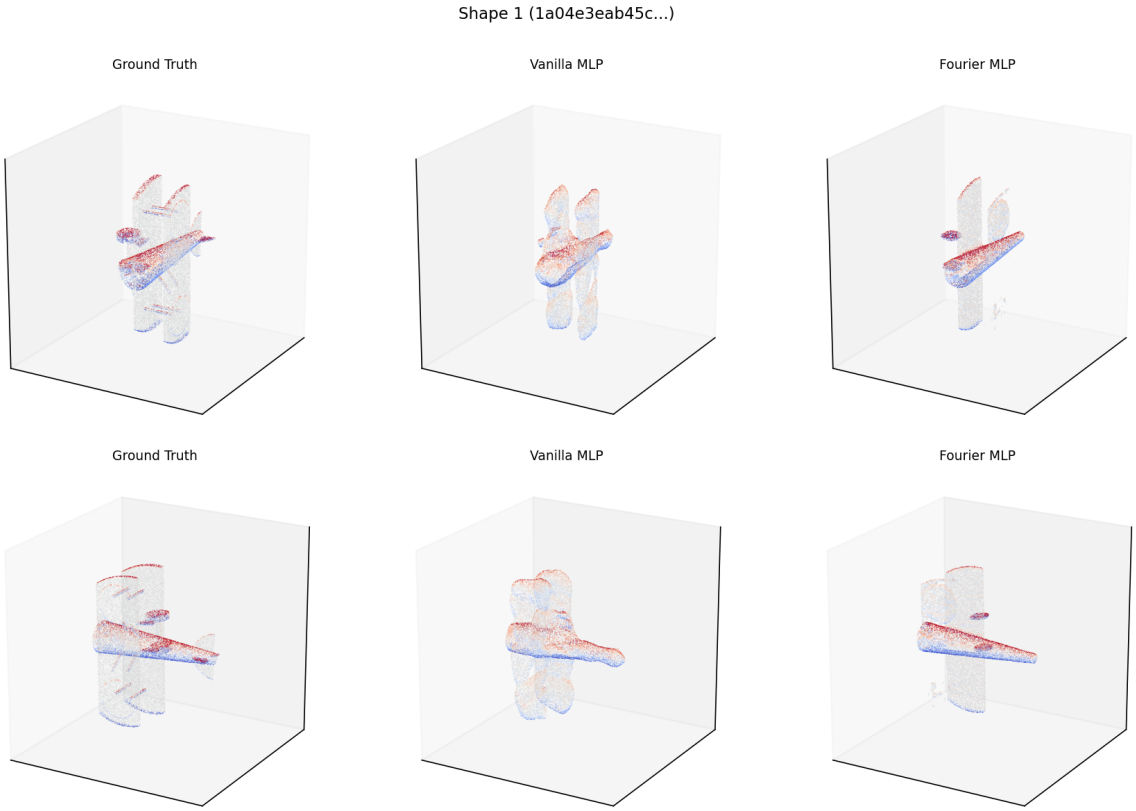


Figure 2: Shape 1 两视角对比

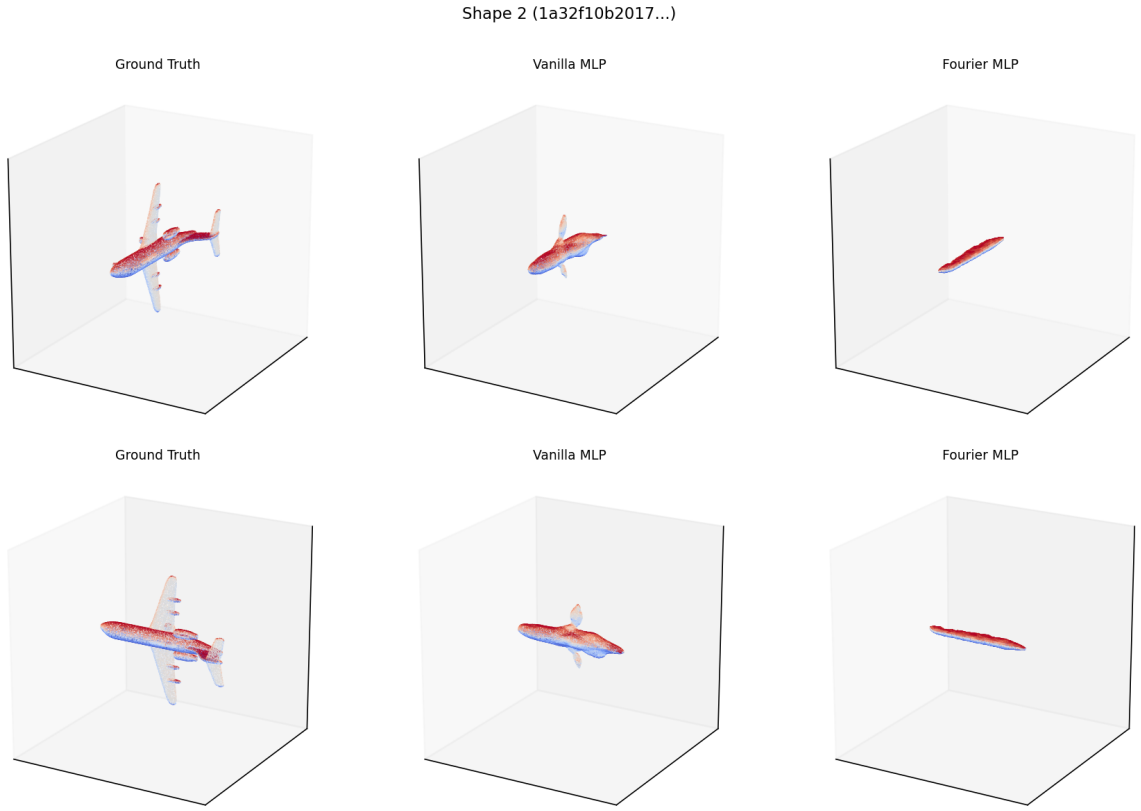


Figure 3: Shape 2 两视角对比

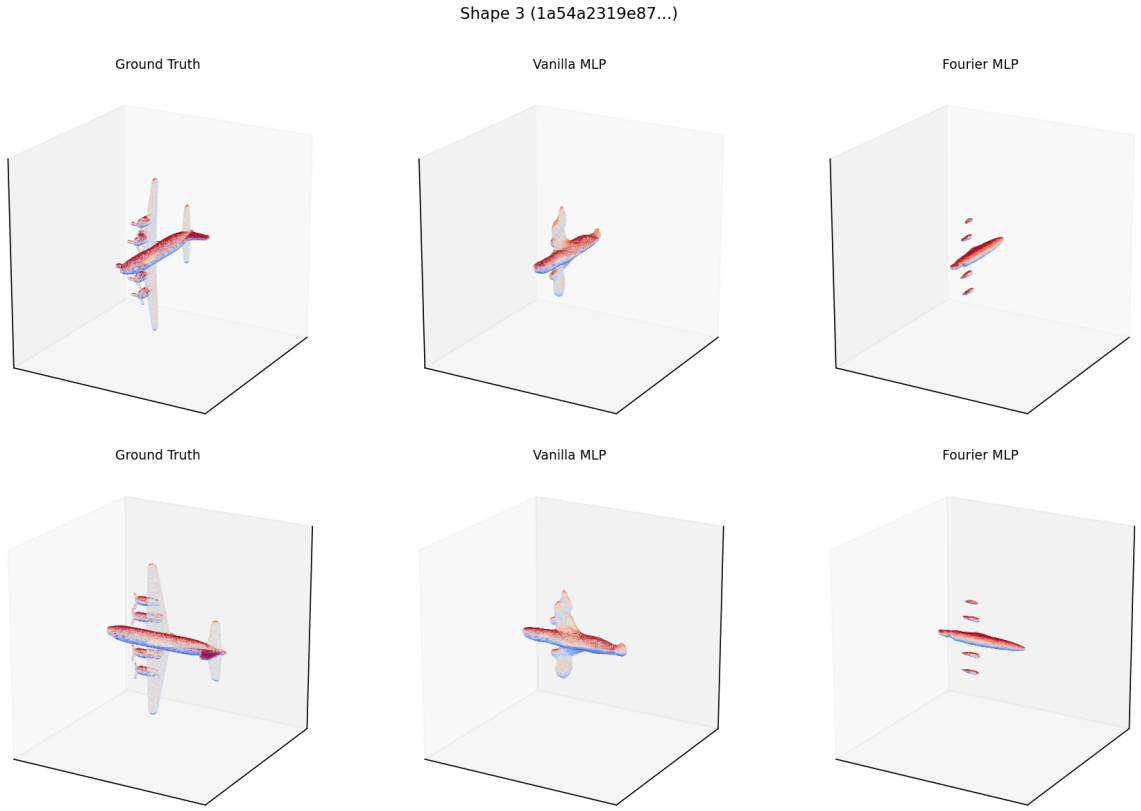


Figure 4: Shape 3 两视角对比

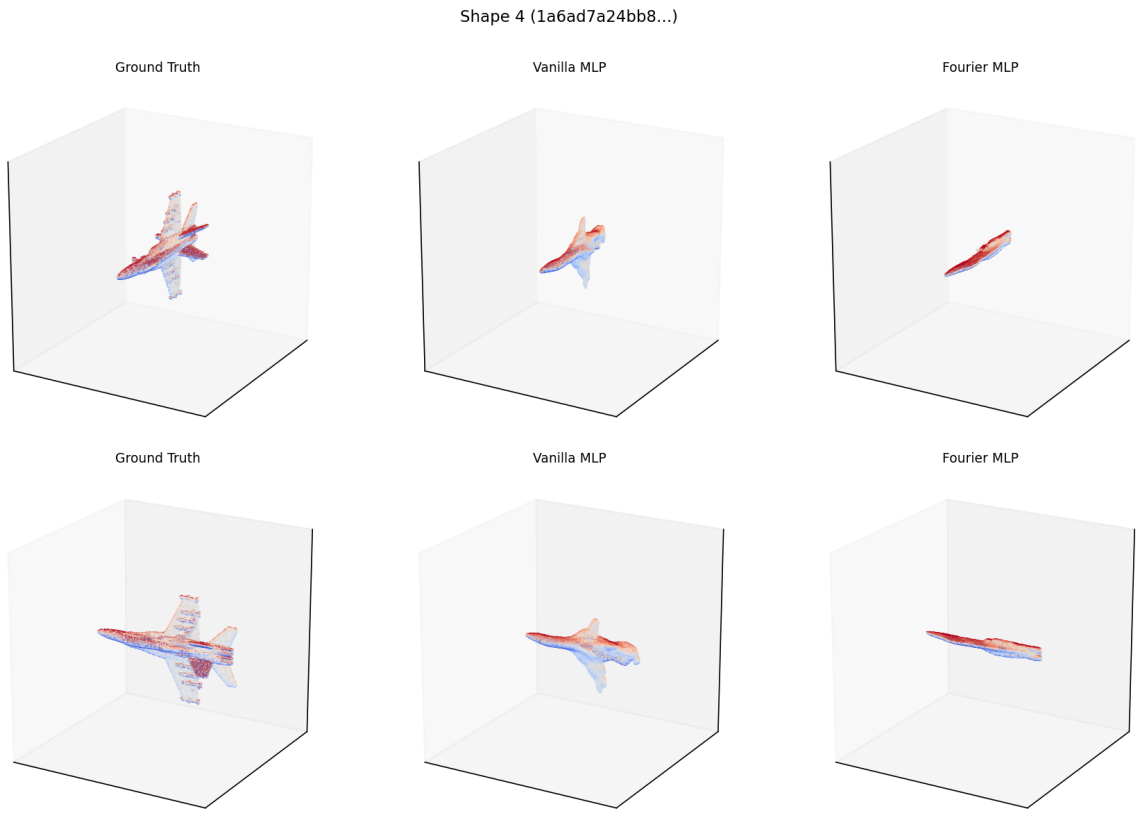


Figure 5: Shape 4 两视角对比

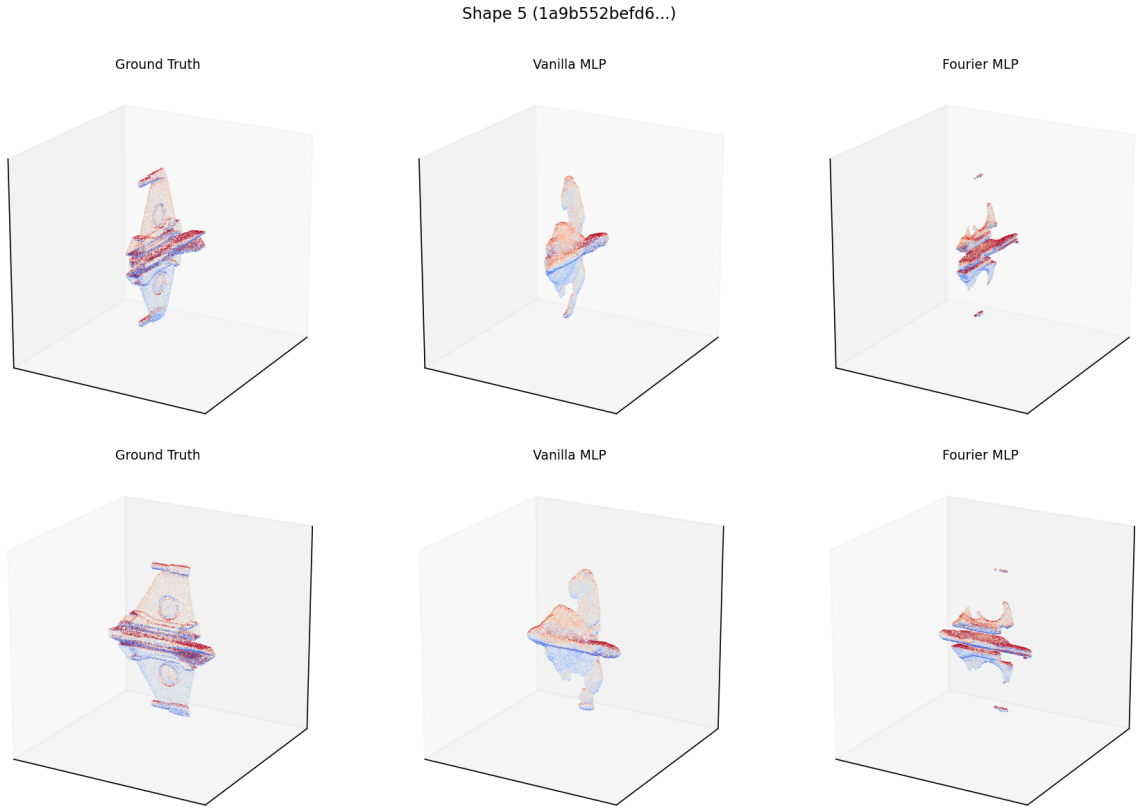


Figure 6: Shape 5 两视角对比

5.3 结果分析

两种方法均能重建出与 Ground Truth 外形相近的飞机形状，整体轮廓（机身、机翼、尾翼）可辨。

Vanilla MLP 的特点：

- SDF 误差极小（$\mathcal{L}_{\text{sdf}} < 0.002$），零等值面位置准确；
- 梯度误差较大（$\mathcal{L}_{\text{grad}} \approx 0.11$–$0.17$），表面法向精度不足；
- 重建表面光滑，但高频细节（翼尖、引擎舱等）被磨平——这正是 MLP 频谱偏置（spectral bias）的体现。

Fourier MLP 的特点：

- 梯度误差显著降低（$\mathcal{L}_{\text{grad}} \approx 0.019$–$0.065$，约为 Vanilla 的 1/3–1/6），说明表面法向预测更准确；
- SDF 绝对误差略有增大，但更多格点对应表面真实法向；
- 部分形状（Shape 1）重建顶点数更多，表面细节更丰富；Shape 2–5 由于数据分布较集中，顶点数略减，但法向质量更好。

6 拓展任务：Fourier Feature 对比分析

6.1 原理

深层 MLP 具有频谱偏置（spectral bias）[3]：在训练早期，网络倾向于先拟合低频成分，高频函数的学习非常缓慢。对于 SDF 重建任务，这意味着 Vanilla MLP 容易生成过于光滑的表面，丢失翼尖、引擎槽等高频几何特征。

Fourier Feature 方法通过随机位置编码：

$$\gamma(q) = [\sin(2\pi \mathbf{B}q),\ \cos(2\pi \mathbf{B}q)]^\top \tag{8}$$

将输入映射到一个内积核函数空间：

$$k(q, q') = e^{-\frac{\pi^2\sigma^2}{2}\|q-q'\|^2} \tag{9}$$

即高斯 RBF 核。当 σ 较大时，核函数带宽窄、支撑高频分量，使得 MLP 能够高效拟合高频细节，克服频谱偏置。

6.2 实验结果对比

从表 2 可以看出：

- 梯度损失（$\mathcal{L}_{\mathbf{grad}}$）：Fourier MLP 在所有 5 个形状上均显著优于 Vanilla MLP，降幅约 50%–85%。这直接验证了 Fourier Feature 对高频分量（法向）的提升作用。
- **SDF** 损失（$\mathcal{L}_{\mathbf{sdf}}$）：Vanilla MLP 在 SDF 绝对值上略优（Shape 2, 3, 5）。这符合预期：高频映射引入更多自由度，网络更容易在 SDF 绝对值上产生波动，但换取了更好的梯度方向。
- 总损失：4/5 形状上 Fourier MLP 总损失更低，综合性能更好。

6.3 从可视化图像中观察

（参见图 1 及图 2–6）

- Vanilla MLP 重建的表面整体更” 圆润”，边缘过渡更模糊；
- Fourier MLP 重建的表面在翼身连接处、尾翼边缘处呈现出更锐利的棱线，法向方向变化更陡峭，视觉上细节更丰富；
- 在 Shape 1（顶点数最多的形状）上，两者差异最为显著，Fourier 重建的机翼轮廓更清晰。

6.4 局限性

- $\sigma = 10$ 时 Fourier 特征覆盖的频率范围已经较高，但仍受限于 128^3 Marching Cubes 分辨率，无法表现比格点间距（约 0.009 m）更细的特征。
- 部分 Fourier 重建网格（Shape 1、3、5）Euler 特征数非零，说明存在拓扑噪声；这是高频拟合与有限 SDF 样本密度之间的权衡。
- 两种方法均采用相同的训练轮数和超参数，实际上 Fourier MLP 可能从更多轮训练或更小的 σ 中受益更多。

7 结论

本次作业成功实现了基于 MLP 和 Fourier Feature MLP 的 SDF 隐式表面重建方法：

- 两种方法均能在约 40 秒内完成 2000 轮训练，并快速提取重建 mesh；
- Vanilla MLP 提供稳定、光滑的重建，SDF 绝对值拟合精度高；
- Fourier Feature MLP 通过位置编码突破频谱偏置，法向预测精度显著提升，重建表面的高频细节更丰富；
- 在绝大多数形状上，Fourier MLP 总损失更低，综合重建质量更优。

References

[1] Tancik, M., Srinivasan, P.P., Mildenhall, B., Fridovich-Keil, S., Raghavan, N., Singhal, U., Ramamoorthi, R., Barron, J.T., Ng, R. *Fourier Features Let Networks Learn High Frequency Functions in Low Dimensional Domains*. NeurIPS, 2020.

[2] Park, J.J., Florence, P., Straub, J., Newcombe, R., Lovegrove, S. *DeepSDF: Learning Continuous Signed Distance Functions for Shape Representation*. CVPR, 2019.

[3] Rahaman, N., Baratin, A., Arpit, D., Draxler, F., Lin, M., Hamprecht, F.A., Bengio, Y., Courville, A. *On the Spectral Bias of Neural Networks*. ICML, 2019.